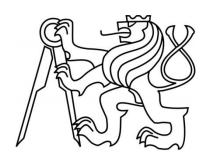
Platform for semantic extraction of the web



Jakub Podlaha

Problem definition

- Design a tool for extracting data from web
 - Data in semi-structured form (HTML)
- Target structure in a form suitable for Semantic Web
- Focus on dynamic, simple solution

Use Cases...

Problem definition

NÁRODNÍ PAMÁTKOVÝ ÚSTAV		MonumNet			Nemovité památky pro tisk: stránka celý výběr do Excelu: stránk	a celý výběr		
Nalezeno: 40203 je chráněno, přírůstky od 03.05.1958 do 10.12.2013								
Stránka 1 / 1609	ka 1 / 1609							
Číslo rejstříku uz	z Název okresu	Sídelní útvar	Část obce	čp.	Památka	Ulice,nám./um		
20339 / 1-1971 <mark>S</mark>	Praha hl.m.	Praha	Běchovice	čp.1	zájezdní hostinec Na Staré poště	Praha 9, Českobrodská		
104764 P	Praha hl.m.	Praha	Benice		zvonička			
40604 / 1-1569 <mark>S</mark>	Praha hl.m.	Praha	Bohnice		kostel sv. Petra a Pavla	Praha 8, Bohnice		
54973 / 1-1628 R	Praha hl.m.	Praha	Bohnice		výšinné opevněné sídliště - hradiště Zámka, archeologické stopy	Praha 8, na ostrohu nad Vltavou		
54974 / 1-1571	Praha hl.m.	Praha	Bohnice	čp.1	venkovská usedlost Vraných	Praha 8, Bohnická		
44366 / 1-1572 5	Praha hl.m.	Praha	Bohnice	čp.4	fara	Praha 8, Bohnická		
54975 / 1-1573	Praha hl.m.	Praha	Bohnice	čp.12	činžovní dům - hospoda Štrasburk	Praha 8, Bohnická		
40605 / 1-1570 R	Praha hl.m.	Praha	Bohnice	čp.91	nemocnice - psychiatrická léčebna	Praha 8, Ústavní, Bohnická		
44368 / 1-1347	Praha hl.m.	Praha	Braník		kostel sv. Prokopa	Praha 4, Školní, Nad kostelem		
44369 / 1-1713 <mark>S</mark>	Praha hl.m.	Praha	Braník	čp.15	Maroldova vila	Praha 4, Stará cesta		
44005 / 4 4070 /		- 1	n 4	v 05	1 1/ 11 / 1 / 1 / 1 / 1			

Problem definition

PAM ÚST	RODNÍ MÁTKOVÝ AV	MonumNet				Nemovité památky pro tisk: stránka celý výběr do Excelu: stránka celý výběr						
Nalezeno: 40203 je chráněno, přírůstky od 03.05.1958 do 10.12.2013 Stránka 1 / 1609												
Číslo rejst	říku uz	Název okresu	Sídelní útvar	Část obce	čp.	Památka	Ulice,nám./um					
20339 / 1-	1971 5	Praha hl.m.	Praha	Běchovice	čp.1	zájezdní hostinec Na Staré poště	Praha 9, Českobrodská					
104764	P	Praha hl.m.	Praha	Benice		zvonička						
40604 / 1-	1569	Praha hl.m.	Praha	Bohnice		kostel sv. Petra a Pavla	Praha 8, Bohnice					
54973 / 1-	1628	<rdf:rdf< td=""></rdf:rdf<>										
54974 / 1-	1571	xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#"										
44366 / 1-	1572	<pre>xmlns:j.0="http://onto.mondis.cz/resource/npu/"</pre>										
4975 / 1-	1573	xmlns:owl="http://www.w3.org/2002/07/owl#"										
40605 / 1-	1570	<pre>xmlns:rdfs="http://www.w3.org/2000/01/rdf-schema#" xmlns:xsd="http://www.w3.org/2001/XMLSchema#" ></pre>										
44368 / 1-	1347	<pre><rdf:description rdf:about="http://kub1x.org/onto/dip/t/npu-201412300182342414/indiv201412300182458526"></rdf:description></pre>										
44369 / 1-	1713	<pre><rdf:type rdf:resource="http://onto.mondis.cz/resource/npu/MonumentRecord"></rdf:type></pre>										
44005 / 4	4070	<j.0:hasdistrict rdf:resource="http://kub1x.org/onto/dip/t/npu-201412300182342414/indiv201412300182458765"></j.0:hasdistrict>										
		<rdf:description rdf:about="http://kub1x.org/onto/dip/t/npu-201412300182342414/indiv201412300182458207"></rdf:description>										
		<pre><rdf:type rdf:resource="http://onto.mondis.cz/resource/npu/District"></rdf:type> <rdfs:label rdf:datatype="http://www.w3.org/2001/XMLSchema#string">R</rdfs:label> </pre>										
		<pre> <rdf:description rdf:about="http://kublx.org/onto/dip/t/npu-201412300182342414/indiv201412300182502529"></rdf:description></pre>										
		<rdf:type rdf:resource="http://onto.mondis.cz/resource/npu/MonumentRecord"></rdf:type>										
		<pre><j.0:hasdistrict rdf:resource="http://kub1x.org/onto/dip/t/npu-201412300182342414/indiv201412300182502774"></j.0:hasdistrict> </pre>										
		<rdf:description rdf:about="http://onto.mondis.cz/resource/npu/District"></rdf:description>										
		<rdf:type rdf:resource="http://www.w3.org/2002/07/owl#Class"></rdf:type>										

Existing solutions

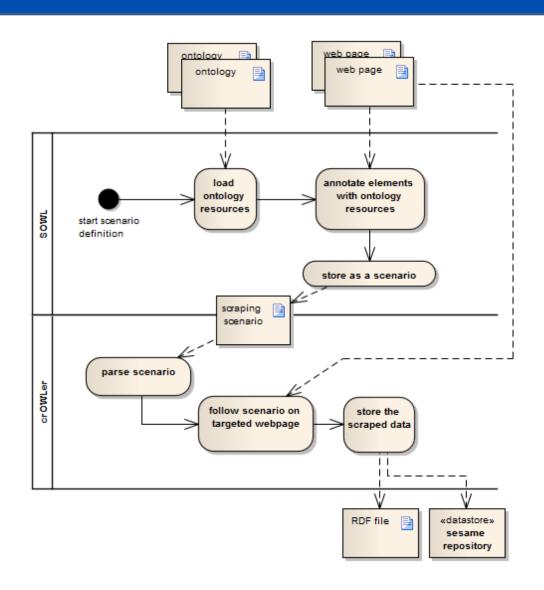
 Rapid prototyping to explore suitable platforms and libraries

- Semantic
 - Strigil, crOWLer, jOWL, rdfquery
- Non-semantic
 - InfoCram 6000, Aardvark, Selenium IDE and Builder, WebDriver

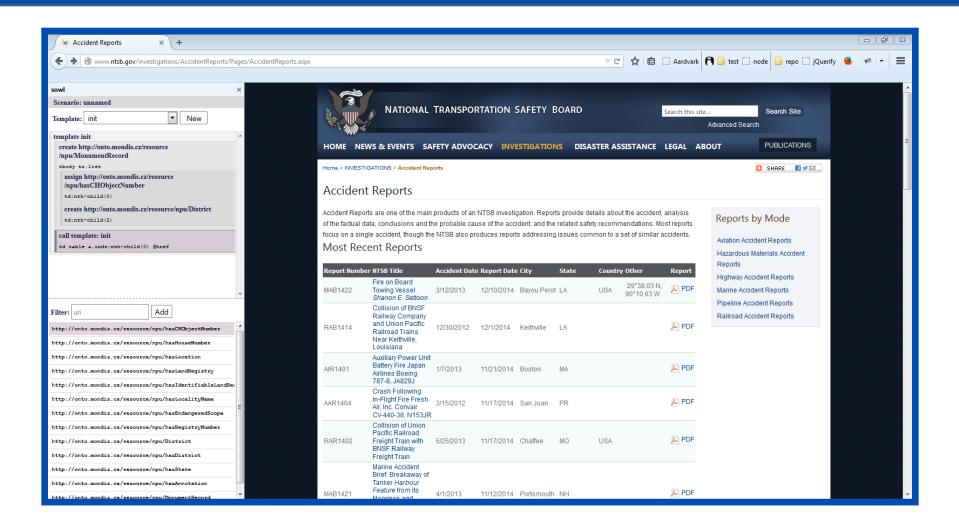
Program design

- Components
 - SOWL frontend, the tool for scenario creation
 - crOWLer backend, the semantic crawler
- Scraping scenario
 - Syntax and semantics of scraping scenario commands
 - Mapping of ontological resources on DOM nodes
 - Elemental data handling
 - JavaScript support

Program workflow



Implementation



Outcomes and future work

- Improvement of current approach in semantic crawling
 - Definition of scraping scenario
 - Architecture and implementation of platform stack
 - Usability and accessibility for end users
- Full implementation of proposed design
- Usability improvements according to users feedback
- Better handling of ontological resources

